

Analyse des Incohérences GPS

dans les Données de l'EACI 2017 au Mali

Détection, Classification et Traitement des Anomalies Géographiques

ZONGO Abdoul Kader

Supervisé par : **Mouhamadou Hady DIALLO**

ISEP2 Semestre 4 — *Traitements Statistiques avec R*
ENSAE Pierre Ndiaye — Dakar

21 mai 2026

Plan de la présentation

- 1 Contexte et Objectifs
- 2 Cadre Conceptuel
- 3 Les 6 Étapes du Pipeline
- 4 Résultats et Analyse
- 5 Discussion et Recommandations
- 6 Conclusion

Contexte général de l'étude

Source des données

- **EACI 2017** : Enquête Agricole de Conjoncture Intégrée au Mali
- Programme **LSMS-ISA** — Banque mondiale
- **953 exploitations** agricoles géoréférencées
- Variables GPS : lat_dd_mod, lon_dd_mod
- **36 variables** géographiques complémentaires

Jittering LSMS

Perturbation **volontaire** des coordonnées GPS pour protéger la confidentialité des ménages.

⇒ *Les doublons détectés proviennent de cette perturbation, et non d'erreurs de collecte.*

Enjeu analytique

Des coordonnées GPS erronées induisent des **biais** sur :

- les estimations de superficie
- les rendements agricoles
- les cartes et analyses spatiales

Objectifs pédagogiques

Obj.	Description
01	Mettre en place un système de validation géographique systématique sous R
02	Construire une taxonomie des erreurs GPS et identifier leurs causes probables
03	Détecter les doublons spatiaux et distinguer leurs origines légitimes des fraudes
04	Quantifier les surfaces cultivées via l'emprise GPS
05	Mesurer l' impact des corrections sur les estimations finales

Les 3 pièges méthodologiques

Piège 1 — Erreur de projection vs vraie anomalie GPS

Un point situé hors des frontières peut résulter d'une *projection mal définie* (corrigeable) et non d'une vraie erreur GPS. Solution : tester dans **deux projections** (EPSG :3857 ET UTM Zone 29N).

Piège 2 — Doublon légitime vs fraude enquêteur

Deux points identiques peuvent correspondre à une *même parcelle visitée deux fois* — une situation parfaitement légitime dans le protocole LSMS-ISA. Ne pas les exclure sans vérification via la variable **passage**.

Piège 3 — Biais de sélection non documenté

Exclure des observations sans en vérifier les caractéristiques équivaut à introduire un *biais de sélection non documenté*. Toujours comparer exclus vs conservés sur les indicateurs géographiques.

Qualité GPS : quatre dimensions complémentaires

Dimension	Question	Indicateur	Méthode
Cohérence territoriale	Dans les frontières du Mali ?	hors mali réel	2 projections
Cohérence spatiale	Hors zone aquatique ?	dans eau, TWI	Dist. > 50 km
Unicité	Non dupliqué ?	doublon	DBSCAN 500m
Représentativité	Non aberrant ?	suspect dist.	Quantile 95%

Score composite additif

$$\text{Score}_i = \text{hors_mali} + \text{eau} + \text{TWI} + \text{doublon} + \text{outlier}$$

$$\in \{0, \dots, 5\}$$

Principe : la **convergence** de plusieurs critères renforce la certitude de l'anomalie.

Score	Niveau	N
0	Bon	473
1-2	À vérifier	463
>2	Suspect	17

Taxonomie des erreurs GPS

Catégorie	Description	Cause probable	Gravité
Erreur de projection	Hors 3857 mais correct en UTM	Confusion CRS	Moyenne
Erreur de saisie	Inversion lat./lon.	Saisie manuelle	Haute
Dérive GPS	Mauvaise réception satellite	Zone forestière / dense	Moyenne
Fraude enquêteur	Coordonnées fictives	Absence sur le terrain	Haute

Piège 1 — Ne pas confondre

Erreur de projection = **corrigible**
 Vraie anomalie GPS = **à exclure**

Règle d'or

On ne corrige **jamais** arbitrairement une coordonnée GPS. On *exclut*, *signale* ou *fusionne*.

Sources de données mobilisées

Source : Données issues de la plateforme de microdonnées de la Banque mondiale — microdata.worldbank.org — Programme **LSMS-ISA**, Mali 2017.

Source	Contenu
eaci_geovariables_2017	Coordonnées GPS de 953 exploitations + 36 variables géographiques (NDVI, TWI, élévation...)
eaci17_s01p1	Identifiants ménages : grappe, exploitation, passage (Piège 2)
eaci17_s7fp2	Données de production agricole déclarée par les ménages

3 projections spatiales

- **EPSG :4326** — WGS84 (degrés)
- **EPSG :3857** — mètres (tous calculs)
- **EPSG :32629** — UTM Zone 29N Mali

Packages R mobilisés

<code>sf</code>	Objets et calculs spatiaux
<code>dplyr</code>	Manipulation des données
<code>ggplot2</code>	Visualisation et cartes
<code>dbscan</code>	Clustering spatial
<code>rnatualearth</code>	Frontières du Mali
<code>units</code>	Calcul de surfaces (ha)
<code>tidyr</code>	Restructuration des données

Vue d'ensemble du pipeline en 6 étapes

N	Étape	Méthode et seuil	Piège
1	Validation géographique	st_intersects() en 2 projections + TWI + NDVI	P1
2	Taxonomie des erreurs	Comparaison projections + NDVI + dist_road	–
3	Doublons spatiaux	DBSCAN (eps=500m) + variable passage	P2
4	Outliers spatiaux	Quantile 95% des distances au centroïde	–
5	Score et décisions	7 règles hiérarchisées et justifiées	P3
6	Sensibilité	Q90%, Q95%, Q97.5%	P3

Choix technique : toutes les distances sont calculées en **EPSG :3857 (mètres)**. Les distances en degrés décimaux (WGS84) sont métriquement incohérentes et ne peuvent pas être utilisées pour DBSCAN.

ÉTAPE 1 — Validation Géographique

Double vérification territoriale

Projection	Hors Mali	Diagnostic
EPSG :3857	Oui	?
+ UTM 29N	Oui	Vraie erreur
EPSG :3857	Oui	?
+ UTM 29N	Non	Erreur proj.

Autres contrôles

- Zones aquatiques : distance > 50 km
- Zones humides : TWI > Q90
- Zones non cultivées : NDVI < Q5
- Zones inhabitées : popdensity < Q5

Résultats

Critère	N
Hors Mali réel	1
Erreur projection	0
Zones aquatiques	297
Zones humides TWI	96
Non cultivées NDVI	48
Zones inhabitées	48

Piège 1 — traité

L'unique point hors Mali reste hors territoire en UTM : c'est une **vraie anomalie GPS** (inversion lat./lon.).

ÉTAPE 2 — Taxonomie des Erreurs GPS

Identification des causes probables

Deux indicateurs supplémentaires sont calculés à partir des variables disponibles :

Erreur de saisie

Condition :

- Point hors Mali réel **ET**
- NDVI normal (zone végétalisée)

Interprétation : probable inversion latitude / longitude lors de la saisie manuelle.

Résultat : **1** cas détecté.

Dérive GPS

Condition :

- Dans le Mali **ET**
- Zone non cultivée ($\text{NDVI} < \text{Q5}$) **ET**
- Loin des routes ($\text{dist_road} > \text{Q90}$)

Interprétation : dérive instrumentale dans une zone éloignée.

Résultat : quelques cas isolés.

Apport de la taxonomie

Elle permet d'orienter les **décisions de correction** : une erreur de saisie peut être corrigée manuellement, une dérive GPS ne peut pas l'être sans GPS de terrain.

ÉTAPE 3 — Détection des Doublons DBSCAN

Principe de DBSCAN

- **eps = 500 m** en EPSG :3857
- **minPts = 2** points pour un cluster
- Calcul en **mètres** — physiquement interprétable

Implication majeure

Sans la variable passage, on aurait exclu **207 observations valides** soit **21.7%** de la base — un biais considérable !

Distinction des origines (Piège 2)

Variable passage + grappe :

Origine	N	Décision
Jittering LSMS	207	Fusionner
Double visite	0	Garder
Fraude probable	0	Exclure

Pourquoi DBSCAN ?

- Aucune forme imposée
- Détecte les outliers naturellement
- Supérieur à k-means pour les GPS

Piège 2 — traité

100% des doublons sont du **jittering LSMS légitime**. Aucune fraude d'enquêteur n'a été détectée dans cette base.

ÉTAPE 4 — Détection des Outliers Spatiaux

Méthode non-paramétrique

- ① Calcul du **centroïde** en EPSG :3857
- ② Distance d_i de chaque point au centroïde
- ③ Seuil : $d_{\text{seuil}} = Q_{0.95}(d_i)$
- ④ Points avec $d_i > d_{\text{seuil}}$: **suspects**

Comparaison des critères

Critère	$\bar{d} + 2\sigma$	Q95%
Normalité requise	Oui	Non
Robust. asymétrie	Non	Oui
Interprétable	Mod.	Oui

Pourquoi Q95% et non $\bar{d} + 2\sigma$?

La distribution des distances est **asymétrique à droite** : l'hypothèse de normalité n'est pas vérifiée. Le Q95% est **robuste** à toute distribution.

Résultats

Indicateur	Valeur
Seuil Q95%	≈ 700 km
Outliers détectés	48
Part de la base	5.0%

ÉTAPE 5 — Score Global et Décisions

Score composite

$$\text{Score}_i = \sum_{k=1}^5 \text{critère}_{ik} \in \{0, \dots, 5\}$$

Score	Niveau	N (%)
0	Bon	473 (49.6%)
1-2	À vérifier	463 (48.6%)
>2	Suspect	17 (1.8%)

7 décisions hiérarchisées

Décision	N
Garder	473
Fusionner jittering	207
Vérifier manuel	262
Imputer coordonnées	10
Corriger projection	0
Garder double visite	0
Exclure	1

Résultat clé

Seul **1 point sur 953** est exclu définitivement — signal très positif sur la **qualité globale** de la collecte EACI 2017.

ÉTAPE 6 — Analyse de Sensibilité (Piège 3)

Principe

Le seuil d'exclusion des outliers est testé pour **3 quantiles** afin de vérifier la **stabilité des estimations**.

Résultats

Q	N excl.	Surf. (ha)	NDVI
Q90%	97	0.612	0.2688
Q95%	49	0.590	0.2659
Q97.5%	25	0.575	0.2627

Écart Q90 – Q97.5

Surface : **0.037 ha** soit < 6% de variation.

NDVI : **0.006** soit < 3% de variation.

Vérification du biais (Piège 3)

Statut	N	NDVI
Conservés	952	0.260
Exclus	1	0.252
Différence	–	3%

Conclusion Piège 3


Différence NDVI de **3%** < seuil de 10% :

Aucun biais de sélection géographique
systématique détecté.

La base nettoyée est **représentative** du territoire enquêté.

Carte géographique des anomalies GPS

Visualisation



Lecture analytique

Points verts (Bons)

- Cohérents avec la géographie agricole
- Zones céréalière, Office du Niger, Sikasso

Points orange (À vérifier)


- Distribution spatiale **diffuse**
- Pas de concentration régionale

Points rouges (Suspects)

- Rares (17) et dispersés
- Pas de clustering spatial
- Incidents individuels, **pas de fraude organisée**

Distribution des distances — Histogramme

Visualisation



Répartition finale par niveau

Niveau	N	%
Bon	473	49.6
À vérifier	463	48.6
Suspect	17	1.8
Total	953	100

Lecture

- Distribution **asymétrique à droite**
- Majorité entre 100 et 500 km
- Zone rouge = **48 outliers**

Signal positif

49.6% d'observations sans aucune anomalie : qualité GPS **globalement satisfaisante**.

Surfaces cultivées et impact des corrections

Objectif 4 — Surfaces estimées

$$\hat{S}_i = \pi \times (100)^2 \times \frac{\text{hybrid_V8}_i}{100}$$

Indicateur	Valeur
Surface GPS (buffer 100m)	3.14 ha
hybrid_V8 moyen	17.9%
Surface cultivée moy.	0.56 ha

Limite : s7cq07 indisponible — hybrid_V8 est le meilleur proxy disponible.

Objectif 5 — Impact corrections

Indicateur	Avant	Après
N obs.	953	952
Surf. (ha)	0.561	0.561
NDVI	0.2600	0.2601
Dist. (km)	307.99	307.81

Pourquoi si stable ?

1 point exclu sur 953 = impact mathématiquement négligeable sur les moyennes. Ce n'est pas un échec : c'est la **preuve** de la bonne qualité initiale.

Forces et limites méthodologiques

Forces

- **Reproductibilité** totale (script R portable)
- **Double projection** : Piège 1 traité
- Variable **passage** : Piège 2 traité
- **Biais documenté** : Piège 3 traité
- EPSG :3857 pour tous les calculs
- Q95% non-paramétrique robuste

Limites

- **Jittering** : faux positifs DBSCAN possibles
- **Seuil 50 km** : ne capture pas le delta intérieur du Niger
- **s7cq07** indisponible : proxy hybrid_V8 utilisé

6 Recommandations opérationnelles

- 1 Former les enquêteurs GPS
- 2 Contrôle CAPI en temps réel
- 3 Double mesure GPS
- 4 Pipeline automatisé post-collecte
- 5 Audit GPS par enquêteur
- 6 Couche hydrographique OSM

Conclusion générale

Bilan — Mission accomplie

- **5 objectifs** pédagogiques atteints
- **6 étapes** du pipeline documentées
- **3 pièges** traités avec preuves empiriques

Résultats clés

Indicateur	Valeur
Observations Bonnes	49.6%
Doublons légitimes	207 / 207
Points exclus	1 / 953
Biais NDVI	3% < 10%
Surface moy.	0.56 ha

Apports méthodologiques

- ➊ Rigueur géométrique (EPSG :3857)
- ➋ Double projection (UTM vs 3857)
- ➌ DBSCAN + variable passage
- ➍ Q95% non-paramétrique
- ➎ Documentation du biais de sélection

*Garantir la qualité GPS n'est
plus un luxe technique :*

**c'est un préalable indispensable à
toute analyse agricole de qualité.**

Merci de votre attention

Questions et discussions

ZONGO Abdoul Kader

ISEP2 S4 — Traitements Statistiques avec R

ENSAE Pierre Ndiaye — Dakar, Sénégal

21 mai 2026