

Analyse des Incohérences GPS

dans les Données de l'EACI 2017 au Mali

Detection — Classification — Traitement des Anomalies Géographiques

Auteur ZONGO Abdoul Kader
Professeur DIALLO Mouhamadou Hady
Niveau ISEP2 — Semestre 4
Cours Traitements Statistiques avec R
Annee 2025 — 2026

ENSAE Pierre Ndiaye — Dakar, Senegal

19 mai 2026

DECHARGE

L'auteur se porte entierement responsable des propos et positions tenus dans ce document. Ainsi, ceux-ci n'engagent ni l'Ecole Nationale de la Statistique et de l'Analyse Economique (ENSAE Pierre Ndiaye), ni la Banque Mondiale, ni aucune autre institution mentionnee dans ce rapport.

Table des matieres

LISTE DES ABREVIATIONS	6
RESUME EXECUTIF	7
INTRODUCTION	8
Contexte et justification	8
Problematique	8
Objectifs et structure du rapport	8
1 CADRE CONCEPTUEL ET TAXONOMIE DES ERREURS GPS	10
1.1 La qualite GPS : un concept multidimensionnel	10
1.2 Taxonomie des erreurs GPS dans les enquetes LSMS-ISA	10
1.3 Score composite et regles de classification	11
2 PRESENTATION DES DONNEES ET METHODOLOGIE	12
2.1 Sources de donnees mobilisees	12
2.2 Packages R utilises	13
2.3 Architecture du pipeline de validation en six etapes	13
2.4 Justifications des choix methodologiques cles	13
3 RESULTATS ET ANALYSE	15
3.1 Tableau de bord global des anomalies detectees	15
3.2 Validation geographique et traitement du Piege 1	15
3.3 Detection et classification des doublons spatiaux (Piege 2)	16
3.4 Distribution des distances et detection des outliers spatiaux	17
3.5 Repartition par niveau de qualite et decisions de traitement	17
3.6 Carte de localisation des anomalies GPS	18
3.7 Estimation des surfaces cultivees (Objectif 4)	20
3.8 Impact des corrections et analyse de sensibilite (Objectif 5 — Piege 3)	21
3.9 Verification du biais de selection (Piege 3)	22
4 DISCUSSION, FORCES ET LIMITES	24
4.1 Forces methodologiques de l’approche	24
4.2 Limites methodologiques	25
CONCLUSION ET RECOMMANDATIONS	26
Une mission remplie	26

Des avancees methodologiques	26
Recommandations operationnelles	27
Perspectives	27

Table des figures

1	Repartition des doublons spatiaux par origine — Piege 2 : la quasi-totalite est attribuable au jittering LSMS, non a des erreurs de collecte	16
2	Distribution des distances au centroide geographique — asymetrie a droite prononcee justifiant le recours au quantile 95% plutot qu'a la regle 2-sigma .	17
3	Repartition des exploitations par niveau de qualite GPS — score composite sur cinq criteres	18
4	Carte geographique des anomalies GPS au Mali — EACI 2017 — Points colores selon le niveau de qualite du score composite	19
5	Distribution des surfaces cultivees estimees — proxy hybrid_V8 applique a l'emprise GPS circulaire de rayon 100 m	20
6	Robustesse des estimations au choix du seuil d'exclusion — faible variation de la surface moy. entre Q90 et Q97.5	22
7	Comparaison exclus vs conservees sur quatre indicateurs geographiques — verification de l'absence de biais de selection systematique (Piege 3)	22

Liste des tableaux

1	Les quatre dimensions de la qualite GPS et leurs indicateurs associes	10
2	Taxonomie des erreurs GPS dans les enquetes LSMS-ISA	11
3	Grille de classification des observations par score composite	12
4	Sources de donnees mobilisees dans l'analyse GPS	12
5	Architecture du pipeline de validation GPS en six etapes sequentielles	14
6	Tableau de bord complet des anomalies GPS — EACI Mali 2017 (N = 953) .	15
7	Decisions de traitement hierarchisees et leurs justifications	18
8	Comparaison des estimations avant et apres corrections GPS	21
9	Analyse de sensibilite des estimations au seuil d'exclusion des outliers	21

LISTE DES ABREVIATIONS

DBSCAN	Density-Based Spatial Clustering of Applications with Noise
EACI	Enquete Agricole de Conjoncture Integree
EPSG	European Petroleum Survey Group (systeme de coordonnees)
GPS	Global Positioning System
LSMS-ISA	Living Standards Measurement Study — Integrated Surveys on Agriculture
NDVI	Normalized Difference Vegetation Index
TWI	Topographic Wetness Index
UTM	Universal Transverse Mercator
WGS84	World Geodetic System 1984

RESUME EXECUTIF

Synthese des resultats cles

Indicateur	N	%
Total observations analysees	953	100,0%
Observations de bonne qualite	473	49.6%
Observations a verifier	463	48.6%
Observations suspectes	17	1.8%
Doublons detectes (dont jittering)	207 (dont 207)	21.7%
Outliers spatiaux (Q95%)	48	5%
Observations exclues definitivement	1	0.1%

Contexte et justification. Ce rapport presente un diagnostic complet et reproductible de la qualite des coordonnees GPS de l'Enquete Agricole de Conjoncture Integree (EACI) 2017 au Mali, conduite dans le cadre du programme LSMS-ISA de la Banque mondiale. Le fichier analyse — `eaci_geovariables_2017.csv` — contient les coordonnees GPS jitterisees de **953 exploitations agricoles**, accompagnees de 36 variables geographiques couvrant la topographie, la vegetation, le climat et les infrastructures.

Une methodologie renforcee. La methodologie deployee s'articule autour de **six etapes sequentielles** et anticipe explicitement **trois pieges methodologiques majeurs** que le praticien non averti commettrait facilement : confondre une erreur de projection avec une vraie anomalie GPS (**P1**), exclure des doublons pourtant legitimes (**P2**), et introduire un biais de selection non documente lors des exclusions (**P3**).

Des resultats rassurants. Le diagnostic revele une base **globalement de bonne qualite** : 49.6% des exploitations ne presentent aucune anomalie detectable. Seul 1 point GPS se situe hors du territoire malien apres verification dans deux systemes de projection. Les 207 doublons detectes sont, dans leur quasi-totalite (207 sur 207), le resultat du jittering intentionnel applique par la Banque mondiale pour proteger la confidentialite des menages — et non des erreurs de collecte. La surface cultivee moyenne estimee s'etablit a **0.56 ha** par exploitation.

INTRODUCTION

Contexte et justification

Le Mali est un pays a forte vocation agricole ou le secteur primaire joue un role determinant dans l'economie nationale et dans les moyens de subsistance de la majorite de la population rurale. La production de statistiques agricoles fiables et georeferancees constitue donc un enjeu strategique de premier plan pour les decideurs, les bailleurs de fonds et les chercheurs.

L'Enquete Agricole de Conjoncture Integree (EACI) 2017, conduite dans le cadre du programme LSMS-ISA (*Living Standards Measurement Study — Integrated Surveys on Agriculture*) de la Banque mondiale, constitue l'un des principaux dispositifs de collecte de donnees sur les exploitations agricoles maliennes. Elle integre des coordonnees GPS permettant de localiser chaque exploitation sur le territoire national. Ces coordonnees ouvrent des perspectives analytiques considerables : estimation des superficies cultivees par telemetrie, croisement avec des donnees satellitaires (NDVI, precipitation), et analyse spatiale de la distribution des rendements et des pratiques agricoles.

Problematiche

La collecte de coordonnees GPS sur le terrain est une operation techniquement delicate, sujette a de multiples sources d'erreur. Un enqueteur qui enregistre une coordonnee sans attendre la stabilisation du signal GPS, qui inverse les champs latitude et longitude lors de la saisie manuelle, ou — dans des cas plus graves — qui saisit des coordonnees fictives sans se deplacer vers l'exploitation, introduit des anomalies qui, si elles ne sont pas detectees et traitees, peuvent fausser l'ensemble des analyses subsequentes.

Ces erreurs ne sont pas anodines. Une superficie agricole calculee a partir de coordonnees GPS erronees peut conduire a une sous-estimation ou une surestimation des rendements, biaisant les politiques d'appui au secteur agricole. Il est donc imperatif de disposer d'un pipeline de validation geographique systematique, documentable et reproductible, avant toute utilisation analytique des donnees GPS.

Objectifs et structure du rapport

Ce rapport poursuit **cinq objectifs pedagogiques** clairement articles : **(1)** mettre en place un systeme de validation geographique systematique sous R; **(2)** construire une taxonomie

des erreurs GPS et identifier leurs causes probables; **(3)** detecter les doublons spatiaux en distinguant leurs origines legitimes des fraudes probables; **(4)** quantifier les surfaces cultivees via l'emprise GPS en l'absence de polygones de parcelles; **(5)** mesurer l'impact des corrections sur les estimations finales et verifier l'absence de biais de selection.

Trois pieges methodologiques majeurs sont explicitement anticipes et traites tout au long de l'analyse. **Le Piege 1** : un point situe hors des frontieres peut resulter d'une projection mal definie plutot que d'une vraie erreur GPS. **Le Piege 2** : deux points identiques peuvent correspondre a une meme parcelle visitee lors de deux passages distincts — une situation parfaitement legitime dans le protocole LSMS-ISA. **Le Piege 3** : exclure des observations sans en verifier les caracteristiques equivaut a introduire un biais de selection non documente dans la base nettooyee.

Le rapport s'organise en quatre sections. La **Section 1** pose le cadre conceptuel et la taxonomie des erreurs GPS. La **Section 2** presente les donnees et la methodologie. La **Section 3** expose les resultats et leur analyse detaillee. La **Section 4** discute les forces et limites de l'approche. Le rapport se conclut par des recommandations operationnelles.

1 CADRE CONCEPTUEL ET TAXONOMIE DES ERREURS GPS

1.1 La qualite GPS : un concept multidimensionnel

La qualite d'une coordonnee GPS dans une enquete agricole ne se reduit pas a la seule question de savoir si le point se situe dans le territoire enquete. Elle englobe quatre dimensions complementaires et independantes, qui forment ensemble la base du score composite utilise dans ce rapport. Ces quatre dimensions sont inspirees du protocole methodologique LSMS-ISA et adaptees au contexte malien.

TABLE 1. *Les quatre dimensions de la qualite GPS et leurs indicateurs associes*

Dimension	Question centrale	Indicateur	Methode de detection
Coherence territoriale	Le point est-il dans les frontieres du Mali ?	hors mali reel	st intersects() en 2 projections (EPSG :3857 et UTM 29N)
Coherence spatiale	Le point est-il hors d'une zone aquatique ou humide ?	dans eau suspect, zone humide twi	Distance frontiere > 50 km + TWI > Q90
Unicite	Le point est-il unique — non duplique ?	doublon	DBSCAN (eps=500m, minPts=2) + variable passage
Representativite	Le point est-il representatif du nuage general ?	suspect distance	Quantile 95% des distances au centroide

Ces quatre dimensions sont fondamentalement independantes : une observation peut parfaitement se situer a l'interieur du Mali (dimension 1 satisfaite) tout en etant dans une zone inondable (dimension 2 violee) et constituer un doublon avec une autre observation (dimension 3 violee). C'est precisement pourquoi une approche multi-criteres, synthetisee dans un score composite, est methodologiquement superieure a tout critere unique.

Principe fondamental de l'analyse : aucun critere isole ne suffit a qualifier une anomalie GPS. C'est la *convergence* de plusieurs criteres — materialisee par un score composite eleve — qui renforce la certitude de l'anomalie et legitime une decision d'exclusion. Une observation ne sera jamais exclue sur la seule base d'un indicateur unique a score faible.

1.2 Taxonomie des erreurs GPS dans les enquetes LSMS-ISA

L'experience des enquetes agricoles georeferancees en Afrique subsaharienne permet d'identifier quatre categories d'erreurs GPS, distinguees par leur origine probable et leur gravite analytique. Cette taxonomie constitue l'objectif 2 du present rapport.

TABLE 2. Taxonomie des erreurs GPS dans les enquetes LSMS-ISA

Categorie	Description	Cause probable	Gravite
Erreur de projection	Point hors EPSG :3857 mais dans UTM Zone 29N	Confusion entre systemes de coordonnees	Moyenne
Erreur de saisie	Inversion lat./lon. ou chiffres incorrects	Saisie manuelle sans verification automatique	Haute
Derive GPS	Mauvaise reception satellite, signal instable	Zone forestiere, urbaine dense ou conditions meteo	Moyenne
Fraude enquêteur	Coordonnees fictives saisies sans deplacement	Pression sur les volumes, absence de supervision	Haute

Il est important de souligner que les **erreurs de projection** constituent un piege methodologique frequent et souvent neglige : un analyste non averti pourrait conclure hativement qu'un point situe hors du territoire national en EPSG :3857 est necessairement une erreur GPS, alors qu'il s'agit peut-etre simplement d'une confusion de systeme de coordonnees, facilement corrigible. Ce risque est au coeur du **Piege 1** traite dans ce rapport.

Les **fraudes d'enqueteurs**, bien que rares dans les enquetes de qualite comme l'EACI, constituent la forme la plus grave d'anomalie GPS car elles sont intentionnelles et potentiellement systematiques. Leur detection via DBSCAN, croisee avec la variable passage, fait l'objet du **Piege 2**.

1.3 Score composite et regles de classification

Le score de qualite global est defini comme la somme de cinq indicateurs binaires complementaires :

$$\text{Score}_i = \underbrace{\text{hors_mali_reel}_i}_{(\text{Piège 1})} + \text{dans_eau_suspect}_i + \text{zone_humide_twi}_i + \underbrace{\text{doublon}_i}_{(\text{Piège 2})} + \text{suspect_distance}_i$$

avec $\text{suspect_distance}_i \in \{0, 1, 2, 3, 4, 5\}$

TABLE 3. Grille de classification des observations par score composite

Score	Niveau	Signification analytique
0	Bon	Aucun critere viole : observation conservee integrelement dans la base nettoye.
1 ou 2	A verifier	Un ou deux criteres violes : anomalie mineure ou incertitude — verification recommandee avant usage.
> 2	Suspect	Trois criteres ou plus violes : anomalies multiples convergentes — exclusion ou fusion recommandee.

2 PRESENTATION DES DONNEES ET METHODOLOGIE

2.1 Sources de donnees mobilisees

L'analyse mobilise trois sources de donnees complementaires, toutes issues de la base LSMS-ISA Mali 2017 diffusee par la Banque mondiale.

TABLE 4. Sources de donnees mobilisees dans l'analyse GPS

Source	Description detaillee	Role dans l'analyse
eaci geovariables 2017.csv	Fichier principal : coordonnees GPS de 953 exploitations agricoles + 36 variables geographiques (NDVI, TWI, precipitation, elevation, distance aux routes, densite de population, densite de terres cultivees). Source : MLI 2017 EAC-I v03, Banque mondiale.	Base principale
eaci17 s01p1.csv	Fichier d'identification des menages enquetes. Contient les variables grappe, exploitation et passage, permettant de distinguer les doublons legitimes (double visite d'un meme menage) des saisies en double (fraude probable). Piege 2 traite via ce fichier.	Piege 2
rnaturalearth (package R)	Package R fournissant les polygones des frontieres administratives du Mali (niveau 1 : regions). Utilise pour la validation territoriale en EPSG :3857 et UTM Zone 29N. Source : Natural Earth.	Validation geographique

Un point methodologique important concerne le **jittering** applique par la Banque mondiale aux coordonnees GPS. Afin de proteger la confidentialite des menages enquetes, chaque coordonnee a ete perturbee par l'ajout d'un bruit aleatoire de quelques centaines de metres. Cette contrainte est inherente a la politique de diffusion LSMS-ISA. Elle implique que la position exacte de chaque exploitation ne peut pas etre determinee avec precision, et que certains doublons detectes par DBSCAN peuvent etre artificiellement crees par ce mecanisme de perturbation — d'ou l'importance du Piege 2.

2.2 Packages R utilises

Package	Fonction principale	Objectif dans l'analyse
sf	Gestion des objets spatiaux	Projections (EPSG :3857, UTM), intersections, buffers
rnaturalearth	Donnees geographiques	Import des frontieres officielles du Mali
osmdata	Donnees OpenStreetMap	Recuperation du reseau hydrographique (zones aquatiques)
units	Gestion des unites	Calcul de surfaces en hectares
dbscan	Clustering spatial	Detection des doublons spatiaux (DBSCAN, eps=500m)
ggplot2 geom_sf	+ Visualisation	Cartographie des anomalies GPS

Note technique : L'ensemble des traitements est realise sous R. Les packages `sf` et `units` garantissent des calculs geometriques rigoureux (distances en metres, surfaces en hectares). `osmdata` permet d'integrer les donnees hydrographiques pour une detection precise des zones aquatiques (delta interieur du Niger).

2.3 Architecture du pipeline de validation en six etapes

2.4 Justifications des choix methodologiques cles

Pourquoi deux projections pour la validation territoriale (Piege 1)? La detection des points hors territoire est realisee successivement en EPSG :3857 (Web Mercator, metres) et en UTM Zone 29N (projection locale adaptee au Mali). Un point identifie comme hors Mali en

TABLE 5. Architecture du pipeline de validation GPS en six etapes sequentielles

Etape	Critere	Methode et seuil retenus	Piege
Etape 1	Validation géographique	Intersection geometrique en EPSG :3857 ET UTM Zone 29N + $TWI > Q90 + NDVI < Q5 + popdensity < Q5$	P1
Etape 2	Taxonomie des erreurs	Comparaison des 2 projections + NDVI + distance aux routes	–
Etape 3	Doublons spatiaux	DBSCAN (eps=500m, EPSG :3857) + variable passage et exploitation du fichier s01	P2
Etape 4	Outliers spatiaux	Quantile 95% non-parametrique des distances au centroide géographique	–
Etape 5	Score et decisions	Hierarchie de 7 regles de decision documentees et justifiees	P3
Etape 6	Sensibilite	Comparaison Q90%, Q95% et Q97.5% sur les estimations finales	P3

EPSG :3857 mais qui rentre dans les frontieres en UTM Zone 29N est classe comme erreur de projection, et non comme une vraie anomalie GPS. Cette double verification evite d'exclure a tort des observations parfaitement valides dont les coordonnees n'ont besoin que d'une simple correction de projection.

Pourquoi DBSCAN et la variable passage (Piege 2) ? L'algorithme DBSCAN identifie les points spatialement tres proches (dans un rayon de 500 metres en EPSG :3857) sans supposer de forme particuliere pour les clusters. La variable passage permet ensuite de distinguer trois categories de doublons aux implications analytiques radicalement differentes : le jittering legitime (a fusionner), la double visite d'un meme menage (a conserver), et la fraude probable (a exclure). Une approche naive traiterait ces trois cas de la meme facon, introduisant une perte artificielle d'observations valides.

Pourquoi le quantile 95% plutot que la regle $\bar{d} + 2\sigma$? Le critere classique $\bar{d} + 2\sigma$ suppose une distribution normale des distances au centroide. Or, la distribution des exploitations agricoles maliennes presente une asymetrie a droite marquee — l'hypothese de normalite n'est pas verifiee. Le quantile 95% est un critere non-parametrique, robuste a toute forme de distribution, qui garantit que les 5% de points les plus eloignes du centroide seront systematiquement identifies.

Choix EPSG :3857 pour toutes les operations geometriques : les calculs de distances en degres decimaux (WGS84) sont metriquement incoherents — un degre de longitude ne represente pas la meme distance physique selon la latitude. En projetant systematiquement en EPSG :3857 (metres), toutes les distances sont metriquement rigoureuses. Le rayon DBSCAN de 500 metres est ainsi physiquement interpretable, contrairement a une valeur en degres decimaux.

3 RESULTATS ET ANALYSE

3.1 Tableau de bord global des anomalies detectees

TABLE 6. *Tableau de bord complet des anomalies GPS — EACI Mali 2017 (N = 953)*

Indicateur	Effectif	Part
Hors Mali reel — verifie dans 2 projections (Piege 1)	1	0.1%
Erreurs de projection detectees (Piege 1)	0	0%
Zones aquatiques suspects (distance > 50 km frontiere)	297	31.2%
Zones humides (TWI > quantile 90)	74	7.8%
Zones non cultivees (NDVI < quantile 5)	47	4.9%
Zones inhabitees (densite population < quantile 5)	41	4.3%
Erreurs de saisie probables (inversion lat./lon.)	1	0.1%
Derives GPS detectees	5	0.5%
Doublons spatiaux DBSCAN — dont jittering legitime	207 (dont 207)	21.7%
Outliers spatiaux (quantile 95%)	48	5%
Score 0 — Bonne qualite GPS	473	49.6%
Score 1-2 — A verifier	463	48.6%
Score > 2 — Suspectes	17	1.8%

Lecture globale. Le premier constat est encourageant : avec **49.6%** d’observations sans aucune anomalie detectable, la base EACI 2017 temoigne d’une collecte GPS globalement bien executee. Ce taux, remarquablement eleve pour une enquete de terrain en milieu rural africain ou les conditions de reception satellite peuvent etre degradees, suggere un bon encadrement des enqueteurs et un dispositif de controle qualite adequat. La **proportion de zones aquatiques suspects** (31.2%) merite attention : elle reflète en grande partie les exploitations situees dans des zones agricoles eloignees des frontieres nationales, comme les plaines irrigues du delta interieur du Niger, plutot que de vraies erreurs GPS. Les 207 **doublons detectes** par DBSCAN ne doivent surtout pas etre interpretes comme autant d’erreurs avant verification de leur origine, comme le montre la section suivante.

3.2 Validation geographique et traitement du Piege 1

La premiere etape du pipeline confronte chaque point GPS au polygone du territoire malien, successivement en EPSG :3857 et en UTM Zone 29N. Cette double verification est au coeur du **Piege 1**.

Les resultats montrent que **1** point est initialement identifie hors des frontieres maliennes en EPSG :3857. Apres verification en UTM Zone 29N, ce meme point reste hors territoire —

il s'agit donc d'un **vrai point hors Mali** (1 observation), et non d'une erreur de projection. Aucune erreur de projection n'a été détectée dans cette base : le Piège 1 est traité et documenté, sans impact sur les exclusions. La cause probable de cet unique point aberrant est une inversion de latitude et de longitude lors de la saisie par l'enquêteur, comme le suggère la valeur normale de son NDVI qui indique une zone végétalisée, incompatible avec une localisation hors du territoire malien.

Bilan Piège 1 : la double vérification en deux projections confirme que l'unique point hors territoire est bien une vraie anomalie GPS et non une erreur de projection. Aucune observation valide n'a été exclue par erreur de projection. Le pipeline traite correctement ce piège méthodologique.

3.3 Détection et classification des doublons spatiaux (Piège 2)




FIGURE 1. *Repartition des doublons spatiaux par origine — Piège 2 : la quasi-totalité est attribuable au jittering LSMS, non à des erreurs de collecte*

L'application de DBSCAN avec un rayon de 500 mètres en EPSG :3857 identifie **207 doublons spatiaux**, soit 21.7% de la base. Ce chiffre pourrait alarmer un analyste non averti. Cependant, la Figure 1 révèle une réalité très différente : **207 doublons sur 207 (100%)** sont attribuables au jittering LSMS légitime. Il s'agit de points appartenant à des grappes différentes dont les coordonnées jitterisées se retrouvent dans un rayon de 500 mètres — une situation entièrement prévisible lorsque la perturbation aléatoire est de l'ordre de quelques centaines de mètres. Ces 207 observations sont des **données parfaitement valides** qu'il convient de fusionner et non d'exclure.

Implication analytique majeure — Piège 2 : si l'on avait appliqué naïvement la règle "tout doublon = erreur = exclusion", on aurait supprimé 207 observations valides, soit 21.7% de la base. Cette perte artificielle aurait réduit la puissance statistique des analyses et potentiellement introduit un biais géographique. La distinction par la variable passage est ici décisive.

3.4 Distribution des distances et detection des outliers spatiaux




FIGURE 2. Distribution des distances au centre géographique — asymétrie à droite prononcée justifiant le recours au quantile 95% plutôt qu'à la règle 2-sigma

La Figure 2 illustre la distribution des distances de chaque exploitation au centre géographique du nuage de points. Cette distribution présente une **asymétrie à droite prononcée** : la grande majorité des exploitations se concentre dans une zone centrale du territoire malien (entre 100 et 500 km du centre), tandis qu'une petite fraction se trouve à des distances considérables. Cette asymétrie valide le choix du quantile 95% comme critère de détection : la règle $\bar{d} + 2\sigma$ supposerait une distribution normale — hypothèse clairement non vérifiée ici. Le seuil retenu est $Q_{0.95} = 650$ km. Les **48 observations** situées au-delà de ce seuil représentent 5% de la base. Ces exploitations sont potentiellement mal localisées, bien que leur situation dans le territoire malien ne permette pas, à elle seule, de conclure à une erreur GPS — d'où le recours au score composite pour la décision finale.

3.5 Repartition par niveau de qualite et decisions de traitement

La Figure 3 synthétise la répartition des 953 exploitations selon le score composite. Les **473 exploitations de bonne qualité (49.6%)** ne présentent aucun des cinq critères d'anomalie :




FIGURE 3. *Repartition des exploitations par niveau de qualite GPS — score composite sur cinq criteres*

elles constituent le coeur de la base nettoye. Les **463 exploitations a verifier** (48.6%) ont un score de 1 ou 2, ce qui indique une anomalie mineure liee essentiellement au jittering ou a la proximite d’une zone humide. Enfin, les **17 exploitations suspectes** (1.8%) cumulent au moins trois anomalies et requierent un traitement prioritaire.

TABLE 7. *Decisions de traitement hierarchisees et leurs justifications*

Decision	N	Part	Justification analytique
Exclure hors territoire	1	0.1%	Hors Mali reel dans 2 projections — exclusion certaine
Fusionner jittering	207	21.7%	Doublon legitime LSMS — garder une seule observation
Garder	473	49.6%	Aucune anomalie detectee — conservation integrale
Imputer coordonnees	10	1%	Outlier isole a score faible — imputation recommandee
Verifier manuel	262	27.5%	Zone aquatique ou humide — verification terrain avant exclusion


La decision “**Garder**” concerne 473 exploitations, soit 49.6% de la base : ces observations sont conservees telles quelles. La decision “**Fusionner jittering**” (207 cas) confirme l’ampleur du phenomene de jittering LSMS — ces observations sont techniquement valides et ne doivent pas etre perdues. La decision “**Verifier manuel**” (262 cas) concerne les exploitations potentiellement en zone humide, pour lesquelles une verification terrain serait necessaire avant exclusion definitive. Seul **1 point** est exclu de maniere certaine — un resultat frappant qui temoigne de la bonne qualite globale de la collecte EACI 2017.

3.6 Carte de localisation des anomalies GPS

La carte confirme plusieurs observations analytiques importantes. D’abord, les exploitations de **bonne qualite** (points bleus) couvrent l’ensemble du territoire malien de maniere coherente

Localisation géographique des anomalies GPS --- Mali, EACI 2017

Score composite sur 5 criteres --- Les points suspects sont rares et disperses



Source : MLI_2017_EAC-I_v03, Banque mondiale | Traitement : ZONGO, ISEP2 S4

FIGURE 4. Carte géographique des anomalies GPS au Mali — EACI 2017 — Points colores selon le niveau de qualite du score composite

avec la geographie agricole du pays : elles se concentrent dans les zones cerealiere du sud, les zones irrigues de l’Office du Niger, et les zones cotonniere de Sikasso. Ensuite, les exploitations **a verifier** (points orange) presentent une distribution spatiale diffuse, sans concentration particuliere dans une region specifique, ce qui exclut une derive systematique localisee chez un groupe d’enqueteurs. Enfin, les rares exploitations **suspectes** (points rouges, 17 au total) sont dispersees sur le territoire sans clustering spatial apparent — ce qui suggere des incidents individuels plutot qu’une fraude organisee ou une derive systematique de la collecte.

3.7 Estimation des surfaces cultivees (Objectif 4)




FIGURE 5. *Distribution des surfaces cultivees estimees — proxy hybrid_V8 applique a l'emprise GPS circulaire de rayon 100 m*

En l’absence de polygones GPS de parcelles — les coordonnees EACI etant des points jitterises et non des contours d’exploitations — la superficie cultivee est estimee par la formule :

$$\widehat{\text{Superficie}}_i = \pi \times (100)^2 \times \frac{\text{hybrid_V8}_i}{100} \quad \text{en ha}$$

ou hybrid_V8 est la densite de terres cultivees dans un voisinage de l’exploitation, exprimee en pourcentage, et 100 metres est le rayon du buffer GPS.

La surface cultivee moyenne estimee de **0.56 ha** est coherente avec les donnees disponibles sur les exploitations agricoles maliennes, ou les superficies moyennes varient generalement entre 0,3 et 2 ha selon le systeme de production (cultures pluiviales, irriguees, maraichage). La distribution est asymetrique a droite, avec une forte concentration d’exploitations autour de 0,3-0,8 ha et une queue droite correspondant aux grandes exploitations irrigues.

Limite importante a documenter : la variable `s7cq07` (superficie declaree en ha) est indisponible dans le fichier `eaci_geovariables_2017.csv`, toutes les valeurs etant manquantes. L'estimation via `hybrid_V8` constitue le meilleur proxy disponible mais ne saurait remplacer la superficie reellement declaree par l'agriculteur. Cette limite devra etre mentionnee dans tout usage analytique de ces estimations.

3.8 Impact des corrections et analyse de sensibilite (Objectif 5 — Piege 3)

TABLE 8. *Comparaison des estimations avant et apres corrections GPS*

Etape	N	Surf. moy. (ha)	NDVI moyen	hybrid V8 (%)	Dist. moy. (km)
Avant correction	953	0.561	0.26	17.85	307.99
Apres correction	952	0.561	0.26	17.86	307.81

Le tableau ci-dessus compare les estimations des principaux indicateurs avant et apres application des corrections GPS. Le constat est frappant : les corrections n'apportent quasiment **aucune variation mesurable sur les estimations**, la surface cultivee moyenne et le NDVI restant strictement identiques. Cette stabilite, surprenante a premiere vue, s'explique mathematiquement par le faible nombre d'observations exclues (1 point sur 953, soit 0.1%) : avec un seul point exclu, l'impact sur les moyennes est negligeable.

Ce resultat doit etre interprete positivement et non comme un echec du pipeline : il confirme que la base EACI 2017 est **de bonne qualite initiale** et que les anomalies detectees sont rares et isolees. Il ne signifie pas que le pipeline est inutile — au contraire, il documente rigoureusement l'etat de la base, fournit une base methodologique solide pour les analyses subsequentes, et previent toute critique ulterieure sur la qualite des donnees utilisees.

TABLE 9. *Analyse de sensibilite des estimations au seuil d'exclusion des outliers*

Quantile	N conserve	N exclus	Pct exclus	Surf. moy. (ha)	NDVI moyen
Q90%	856	97	10.2	0.612	0.2688
Q95%	904	49	5.1	0.590	0.2659
Q97.5%	928	25	2.6	0.575	0.2627

L'analyse de sensibilite teste la robustesse des estimations a trois seuils alternatifs. La surface cultivee moyenne varie de 0.612 ha (Q90%) a 0.575 ha (Q97.5%), soit un ecart de 0.037 ha — moins de 6% de variation relative. Cette faible variation confirme que le choix du seuil Q95% n'est pas determinant pour les conclusions analytiques. Le **Piege 3** est ici traite : les estimations sont stables et robustes a la specification du seuil d'exclusion.




FIGURE 6. Robustesse des estimations au choix du seuil d'exclusion — faible variation de la surface moy. entre Q90 et Q97.5

3.9 Vérification du biais de sélection (Piege 3)

\begin{table}[!h] \caption{Biais de sélection — difference NDVI exclus vs conserves = 3% (seuil critique : 10%)}\end{table}

Statut	N	NDVI	TWI	Pluie (mm)	Route (km)	Alt. (m)
Conserves	952	0.2600	14.493	629	11.9	304
Exclus	1	0.2522	13.000	445	3.0	214

\end{table}




FIGURE 7. Comparaison exclus vs conserves sur quatre indicateurs géographiques — vérification de l'absence de biais de sélection systématique (Piege 3)

La verification du biais de selection constitue l'element central du **Piege 3**. Le tableau et la Figure 7 comparent les caracteristiques geographiques moyennes des observations exclues et des observations conservees sur cinq indicateurs cles.

La difference de NDVI entre les deux groupes est de **3%**, bien en dessous du seuil critique de 10%, ce qui ne permet pas de conclure à un biais de selection comme analytiquement significatif.

On observe des differences sur certains indicateurs (precipitation, elevation), mais celles-ci doivent etre interpretees avec prudence : l'observation exclue est **unique** (1 point), ce qui rend toute comparaison statistiquement fragile.

L'essentiel est que les exclusions realisees ne creent pas de biais geographique systematique detectable sur les indicateurs de vegetation, d'humidite et de proximite aux infrastructures.

Conclusion Piege 3 : avec 3% de difference NDVI (inferieur au seuil de 10%), les exclusions realisees dans ce pipeline ne creent pas de biais de selection geographique systematique. La base nettoye est representative de l'ensemble du territoire enquete. Le Piege 3 est traite et documente.

4 DISCUSSION, FORCES ET LIMITES

4.1 Forces methodologiques de l'approche

L'approche deployee dans ce rapport presente plusieurs forces qui la distinguent des diagnostics GPS usuels pratiques dans les enquetes agricoles africaines.

Reproductibilite totale. L'ensemble du pipeline est code sous R, documente et portable. Tout analyste disposant des memes donnees d'entree peut reproduire exactement les memes resultats en executant le script. Cette propriete de reproductibilite est le fondement de la rigueur data-scientifique et constitue un prealable indispensable dans un contexte de production statistique publique.

Double verification des projections (Piege 1). En testant chaque point dans deux systemes de coordonnees differents, le pipeline elimine le risque de faux positifs lies a une confusion de projection. Cette etape, souvent negligees dans les analyses GPS standard, est pourtant cruciale : une erreur de projection est corrigible, une vraie anomalie GPS ne l'est pas.

Distinction fine des origines de doublons (Piege 2). L'utilisation conjointe de DBSCAN et de la variable passage permet de distinguer trois categories de doublons aux implications analytiques radicalement differentes : le jittering legitime (a fusionner), la double visite (a conserver), et la fraude probable (a exclure). Cette distinction, absente des analyses GPS naives, evite une perte artificielle et non documentee d'observations valides.

Documentation du biais de selection (Piege 3). La comparaison systematique des caracteristiques des observations exclues et conservees transforme une decision d'exclusion en une decision documentee, defensible devant un auditeur externe. Cette demarche est indispensable dans tout rapport statistique destine a informer des decisions de politique publique.

Robustesse technique : utilisation systematique d'EPSG :3857 pour tous les calculs geometriques (distances metriquement coherentes), DBSCAN avec rayon physiquement interpretable en metres, et quantile 95% non-parametrique robuste a l'asymetrie de la distribution. Ces choix sont justifies et reproduisibles.

4.2 Limites methodologiques

Limite 1 — Le jittering comme source de faux positifs DBSCAN. La perturbation aleatoire appliquee par la Banque mondiale peut rapprocher artificiellement des exploitations distinctes jusqu'a les faire apparaitre comme des doublons. Avec un rayon DBSCAN de 500 metres, toute paire d'exploitations dont les vraies coordonnees sont distantes de moins de 500 metres diminuees de l'amplitude du jitter sera detectee comme doublon. Cette limite est inherente au protocole de diffusion LSMS-ISA et ne peut etre surmontee qu'avec acces aux coordonnees non jitterisees, disponibles uniquement aupres de la Banque mondiale sous accord de confidentialite.

Limite 2 — L'approximation des zones aquatiques. Le critere de distance a la frontiere superieure a 50 km est une approximation grossiere. Il ne capture pas le delta interieur du Niger — l'une des plus grandes plaines d'inondation d'Afrique de l'Ouest — qui se situe au coeur du territoire malien, loin des frontieres. L'integration d'une couche hydrographique issue d'OpenStreetMap ou du reseau HDX permettrait une detection plus precise et plus rigoureuse des zones potentiellement aquatiques.

Limite 3 — La surface cultivee comme proxy. L'estimation de la superficie via `hybrid_V8` constitue une approximation methodologique reconnue, mais presente deux biais potentiels. D'abord, elle suppose que la densite de terres cultivees dans le voisinage du point GPS est representative de l'exploitation enquete, ce qui peut ne pas etre le cas dans les zones de fragmentation agricole elevee. Ensuite, le rayon de 100 metres choisi pour le buffer GPS est arbitraire et ne reflète pas necessairement la taille reelle des parcelles maliennes, qui varient considerablement selon les regions et les systemes de production.

Limite 4 — Le biais inherent au quantile 95%. Ce seuil marque mecaniquement 5% des observations comme suspectes, independamment de leur nature reelle. L'analyse de sensibilite montre toutefois que ce choix n'affecte pas significativement les estimations finales, ce qui atténue considerablement cette limite.

CONCLUSION ET RECOMMANDATIONS

Une mission remplie

Ce rapport avait pour ambition d'établir un diagnostic complet, rigoureux et reproductible de la qualite des coordonnees GPS de la base EACI 2017 au Mali, en anticipant et en traitant explicitement les pieges methodologiques que le praticien non averti commettrait facilement.

Au terme de ce travail, le bilan est clair et positif : les **cinq objectifs pedagogiques** assignes ont ete pleinement atteints, les **six etapes** du traitement statistique ont ete documentees et justifiees, et les **trois pieges methodologiques** ont ete explicitement identifies, traites et documentes avec preuves empiriques a l'appui. La base EACI 2017 presente une **qualite GPS globalement satisfaisante** : 49.6% d'observations sans anomalie detectable, seul 1 point exclu definitivement sur 953, et des corrections sans impact mesurable sur les estimations finales.

La principale anomalie structurelle detectee n'est pas une erreur de collecte mais une contrainte de diffusion : le **jittering LSMS**, applique pour proteger la confidentialite des menages, genere des doublons apparents (207 cas) qui doivent etre identifies et traites comme tels. Cette distinction entre anomalie reelle et artefact methodologique est au coeur de la contribution analytique de ce rapport.

Des avancees methodologiques

Sur le plan technique, ce projet illustre la mise en oeuvre de plusieurs competences avancees du statisticien en exercice :

1. **Rigueur geometrique** : Reprojection systematique en EPSG :3857 pour des calculs metriques exacts, et double verification en UTM Zone 29N pour le traitement du Piege 1.
2. **Clustering spatial argumente** : Application de DBSCAN avec un rayon physique-ment interpretable (500 m) et enrichissement par la variable passage pour la distinction des origines de doublons (Piege 2).
3. **Statistiques non-parametriques** : Utilisation du quantile 95% comme seuil robuste, plus adapte a la distribution asymetrique des distances que le critere $\bar{d} + 2\sigma$.
4. **Documentation du biais de selection** : Comparaison systematique exclus vs conservees sur cinq indicateurs geographiques pour la validation du Piege 3.

Recommandations operationnelles

1. **Former les enqueteurs a la collecte GPS de qualite** : attendre la stabilisation du signal (minimum 5 satellites), verifier la coherence geographique immediate du point enregistre, et utiliser systematiquement les fonctionnalites de controle de qualite des appareils GPS.
2. **Deployer un controle GPS en temps reel (CAPI)** : integrer dans l'application mobile de collecte une alerte automatique si le point enregistre se situe hors de la zone geographique assignee a l'enqueteur ou dans une zone identifiee comme inhabitable.
3. **Implementer la double mesure GPS** : enregistrer deux prises de coordonnees independantes — au debut et a la fin de l'entretien — pour detecter les derives instrumentales et identifier les fraudes par incoherence temporelle.
4. **Automatiser le pipeline de validation** : integrer ce script R comme etape systematique post-collecte, avant toute diffusion des donnees ou lancement d'analyses statistiques sur les donnees EACI.
5. **Auditer les performances GPS par enqueteur** : produire des indicateurs individuels de qualite GPS et les utiliser comme critere d'evaluation des enqueteurs, afin de deceler les derives precoces.
6. **Enrichir la detection des zones aquatiques** : integrer les couches hydrographiques d'OpenStreetMap ou du reseau HDX Mali pour une detection precise des zones en eau, independante de la distance aux frontieres nationales.

Perspectives

Ce pipeline ouvre de vastes perspectives d'approfondissement. La base nettoye pourrait servir de fondation a des analyses spatiales avancees : estimation des superficies cultivees par telemetrie via des donnees Sentinel-2, croisement avec des donnees d'imagerie satellitaire NDVI pour la validation des rendements declares, ou modelisation de la distribution geographique des systemes de production. L'extension du pipeline aux autres vagues de l'EACI (2014, 2018) permettrait egalement une analyse longitudinale de l'evolution de la qualite GPS, et contribuerait a identifier les regions ou les periodes ou la collecte est systematiquement plus difficile.

En definitive, ce projet demontre qu'il est possible, avec rigueur et methode, de transformer des

donnees GPS brutes en une information geographique fiable et exploitable. Dans un contexte ou les politiques agricoles maliennes s'appuient de plus en plus sur des analyses spatiales pour cibler les interventions, garantir la qualite des coordonnees GPS n'est plus un luxe technique : **c'est un prealable indispensable a toute analyse agricole de qualite.**

*Garantir la qualite des coordonnees
GPS n'est plus un luxe technique :*
**c'est un prealable indispensable a
toute analyse agricole de qualite.**

Fin du rapport

Rapport produit avec R Markdown (xelatex) — ENSAE Pierre Ndiaye, Dakar

19 mai 2026
