

Analyse des Incohérences GPS

dans les Données de l'EACI 2017 au Mali

Détection — Classification — Traitement des Anomalies Géographiques

Auteur ZONGO Abdoul Kader

Professeur DIALLO Mouhamadou Hady

Niveau ISEP2 — Semestre 4

Cours Traitements Statistiques avec R

Année 2025 — 2026

ENSAE Pierre Ndiaye — Dakar, Sénégal

20 mai 2026

DÉCHARGE

L'auteur se porte entièrement responsable des propos et positions tenus dans ce document. Ainsi, ceux-ci n'engagent ni l'École Nationale de la Statistique et de l'Analyse Économique (ENSAE Pierre Ndiaye), ni la Banque Mondiale, ni aucune autre institution mentionnée dans ce rapport.

Table des matières

LISTE DES ABRÉVIATIONS	6
RÉSUMÉ EXÉCUTIF	7
INTRODUCTION	8
Contexte et justification	8
Problématique	8
Objectifs et structure du rapport	8
1 CADRE CONCEPTUEL ET TAXONOMIE DES ERREURS GPS	10
1.1 La qualité GPS : un concept multidimensionnel	10
1.2 Taxonomie des erreurs GPS dans les enquêtes LSMS-ISA	10
1.3 Score composite et règles de classification	11
2 PRÉSENTATION DES DONNÉES ET MÉTHODOLOGIE	13
2.1 Sources de données mobilisées	13
2.2 Packages R utilisés	14
2.3 Architecture du pipeline de validation en six étapes	15
2.4 Justifications des choix méthodologiques clés	15
3 RÉSULTATS ET ANALYSE	17
3.1 Tableau de bord global des anomalies détectées	17
3.2 Validation géographique et traitement du Piège 1	17
3.3 Détection et classification des doublons spatiaux (Piège 2)	18
3.4 Distribution des distances et détection des outliers spatiaux	19
3.5 Répartition par niveau de qualité et décisions de traitement	19
3.6 Carte de localisation des anomalies GPS	22
3.7 Estimation des surfaces cultivées (Objectif 4)	22
3.8 Impact des corrections et analyse de sensibilité (Objectif 5 — Piège 3)	23
3.9 Vérification du biais de sélection (Piège 3)	24
4 DISCUSSION, FORCES ET LIMITES	26
4.1 Forces méthodologiques de l'approche	26
4.2 Limites méthodologiques	27
CONCLUSION ET RECOMMANDATIONS	28
Une mission remplie	28

Des avancées méthodologiques	28
Recommandations opérationnelles	29
Perspectives	29

Table des figures

1	Répartition des doublons spatiaux par origine — Piège 2 : la quasi-totalité est attribuable au jittering LSMS, non à des erreurs de collecte	18
2	Distribution des distances au centroïde géographique — asymétrie à droite prononcée justifiant le recours au quantile 95% plutôt qu'à la règle 2-sigma .	19
3	Répartition des exploitations par niveau de qualité GPS — score composite sur cinq critères	20
4	Carte géographique des anomalies GPS au Mali — EACI 2017 — Points colorés selon le niveau de qualité du score composite	21
5	Distribution des surfaces cultivées estimées — proxy hybrid_V8 appliqué à l'emprise GPS circulaire de rayon 100 m	22
6	Robustesse des estimations au choix du seuil d'exclusion — faible variation de la surface moy. entre Q90 et Q97.5	24
7	Comparaison exclus vs conservés sur quatre indicateurs géographiques — vérification de l'absence de biais de sélection systématique (Piège 3)	25

Liste des tableaux

1	Les quatre dimensions de la qualité GPS et leurs indicateurs associés	10
2	Taxonomie des erreurs GPS dans les enquêtes LSMS-ISA	11
3	Grille de classification des observations par score composite	12
4	Sources de données mobilisées dans l'analyse GPS	13
5	Architecture du pipeline de validation GPS en six étapes séquentielles	15
6	Tableau de bord complet des anomalies GPS — EACI Mali 2017 (N = 953) .	17
7	Décisions de traitement hiérarchisées et leurs justifications	20
8	Comparaison des estimations avant et après corrections GPS	23
9	Analyse de sensibilité des estimations au seuil d'exclusion des outliers	23

LISTE DES ABRÉVIATIONS

DBSCAN	Density-Based Spatial Clustering of Applications with Noise
EACI	Enquête Agricole de Conjoncture Intégrée
EPSG	European Petroleum Survey Group (système de coordonnées)
GPS	Global Positioning System
LSMS-ISA	Living Standards Measurement Study — Integrated Surveys on Agriculture
NDVI	Normalized Difference Vegetation Index
TWI	Topographic Wetness Index
UTM	Universal Transverse Mercator
WGS84	World Geodetic System 1984

RÉSUMÉ EXÉCUTIF

Synthèse des résultats clés

Indicateur	N	%
Total observations analysées	953	100,0%
Observations de bonne qualité	473	49.6%
Observations à vérifier	463	48.6%
Observations suspectes	17	1.8%
Doublons détectés (dont jittering)	207 (dont 207)	21.7%
Outliers spatiaux (Q95%)	48	5%
Observations exclues définitivement	1	0.1%

Contexte et justification. Ce rapport présente un diagnostic complet et reproductible de la qualité des coordonnées GPS de l'Enquête Agricole de Conjoncture Intégrée (EACI) 2017 au Mali, conduite dans le cadre du programme LSMS-ISA de la Banque mondiale. Le fichier analysé — `eaci_geovariables_2017.csv` — contient les coordonnées GPS jitterisées de **953 exploitations agricoles**, accompagnées de 36 variables géographiques couvrant la topographie, la végétation, le climat et les infrastructures.

Une méthodologie renforcée. La méthodologie déployée s'articule autour de **six étapes séquentielles** et anticipe explicitement **trois pièges méthodologiques majeurs** que le praticien non averti commettrait facilement : confondre une erreur de projection avec une vraie anomalie GPS (**P1**), exclure des doublons pourtant légitimes (**P2**), et introduire un biais de sélection non documenté lors des exclusions (**P3**).

Des résultats rassurants. Le diagnostic révèle une base **globalement de bonne qualité** : 49.6% des exploitations ne présentent aucune anomalie détectable. Seul 1 point GPS se situe hors du territoire malien après vérification dans deux systèmes de projection. Les 207 doublons détectés sont, dans leur quasi-totalité (207 sur 207), le résultat du jittering intentionnel appliqué par la Banque mondiale pour protéger la confidentialité des ménages — et non des erreurs de collecte. La surface cultivée moyenne estimée s'établit à **0.56 ha** par exploitation.

INTRODUCTION

Contexte et justification

Le Mali est un pays à forte vocation agricole où le secteur primaire joue un rôle déterminant dans l'économie nationale et dans les moyens de subsistance de la majorité de la population rurale. La production de statistiques agricoles fiables et géoréférencées constitue donc un enjeu stratégique de premier plan pour les décideurs, les bailleurs de fonds et les chercheurs.

L'Enquête Agricole de Conjoncture Intégrée (EACI) 2017, conduite dans le cadre du programme LSMS-ISA (*Living Standards Measurement Study — Integrated Surveys on Agriculture*) de la Banque mondiale, constitue l'un des principaux dispositifs de collecte de données sur les exploitations agricoles maliennes. Elle intègre des coordonnées GPS permettant de localiser chaque exploitation sur le territoire national. Ces coordonnées ouvrent des perspectives analytiques considérables : estimation des superficies cultivées par télémétrie, croisement avec des données satellitaires (NDVI, précipitation), et analyse spatiale de la distribution des rendements et des pratiques agricoles.

Problématique

La collecte de coordonnées GPS sur le terrain est une opération techniquement délicate, sujette à de multiples sources d'erreur. Un enquêteur qui enregistre une coordonnée sans attendre la stabilisation du signal GPS, qui inverse les champs latitude et longitude lors de la saisie manuelle, ou — dans des cas plus graves — qui saisit des coordonnées fictives sans se déplacer vers l'exploitation, introduit des anomalies qui, si elles ne sont pas détectées et traitées, peuvent fausser l'ensemble des analyses subséquentes.

Ces erreurs ne sont pas anodines. Une superficie agricole calculée à partir de coordonnées GPS erronées peut conduire à une sous-estimation ou une surestimation des rendements, biaisant les politiques d'appui au secteur agricole. Il est donc impératif de disposer d'un pipeline de validation géographique systématique, documentable et reproductible, avant toute utilisation analytique des données GPS.

Objectifs et structure du rapport

Ce rapport poursuit **cinq objectifs pédagogiques** clairement articulés : **(1)** mettre en place un système de validation géographique systématique sous R ; **(2)** construire une taxonomie

des erreurs GPS et identifier leurs causes probables ; **(3)** détecter les doublons spatiaux en distinguant leurs origines légitimes des fraudes probables ; **(4)** quantifier les surfaces cultivées via l’emprise GPS en l’absence de polygones de parcelles ; **(5)** mesurer l’impact des corrections sur les estimations finales et vérifier l’absence de biais de sélection.

Trois pièges méthodologiques majeurs sont explicitement anticipés et traités tout au long de l’analyse. **Le Piège 1** : un point situé hors des frontières peut résulter d’une projection mal définie plutôt que d’une vraie erreur GPS. **Le Piège 2** : deux points identiques peuvent correspondre à une même parcelle visitée lors de deux passages distincts — une situation parfaitement légitime dans le protocole LSMS-ISA. **Le Piège 3** : exclusion des observations sans en vérifier les caractéristiques équivaut à introduire un biais de sélection non documenté dans la base nettoyée.

Le rapport s’organise en quatre sections. La **Section 1** pose le cadre conceptuel et la taxonomie des erreurs GPS. La **Section 2** présente les données et la méthodologie. La **Section 3** expose les résultats et leur analyse détaillée. La **Section 4** discute les forces et limites de l’approche. Le rapport se conclut par des recommandations opérationnelles.

1 CADRE CONCEPTUEL ET TAXONOMIE DES ERREURS GPS

1.1 La qualité GPS : un concept multidimensionnel

La qualité d'une coordonnée GPS dans une enquête agricole ne se réduit pas à la seule question de savoir si le point se situe dans le territoire enquêté. Elle englobe quatre dimensions complémentaires et indépendantes, qui forment ensemble la base du score composite utilisé dans ce rapport. Ces quatre dimensions sont inspirées du protocole méthodologique LSMS-ISA et adaptées au contexte malien.

TABLE 1. *Les quatre dimensions de la qualité GPS et leurs indicateurs associés*

Dimension	Question centrale	Indicateur	Méthode de détection
Cohérence territoriale	Le point est-il dans les frontières du Mali ?	hors mali réel	st intersects() en 2 projections (EPSG :3857 et UTM 29N)
Cohérence spatiale	Le point est-il hors d'une zone aquatique ou humide ?	dans eau suspect, zone humide twi	Distance frontière > 50 km + TWI > Q90
Unicité	Le point est-il unique — non dupliqué ?	doublon	DBSCAN (eps=500m, minPts=2) + variable passage
Représentativité	Le point est-il représentatif du nuage général ?	suspect distance	Quantile 95% des distances au centroïde

Ces quatre dimensions sont fondamentalement indépendantes : une observation peut parfaitement se situer à l'intérieur du Mali (dimension 1 satisfaite) tout en étant dans une zone inondable (dimension 2 violée) et constituer un doublon avec une autre observation (dimension 3 violée). C'est précisément pourquoi une approche multi-critères, synthétisée dans un score composite, est méthodologiquement supérieure à tout critère unique.

Principe fondamental de l'analyse : aucun critère isolé ne suffit à qualifier une anomalie GPS. C'est la *convergence* de plusieurs critères — matérialisée par un score composite élevé — qui renforce la certitude de l'anomalie et légitime une décision d'exclusion. Une observation ne sera jamais exclue sur la seule base d'un indicateur unique à score faible.

1.2 Taxonomie des erreurs GPS dans les enquêtes LSMS-ISA

L'expérience des enquêtes agricoles géoréférencées en Afrique subsaharienne permet d'identifier quatre catégories d'erreurs GPS, distinguées par leur origine probable et leur gravité analytique. Cette taxonomie constitue l'objectif 2 du présent rapport.

TABLE 2. *Taxonomie des erreurs GPS dans les enquêtes LSMS-ISA*

Catégorie	Description	Cause probable	Gravité
Erreur de projection	Point hors EPSG :3857 mais dans UTM Zone 29N	Confusion entre systèmes de coordonnées	Moyenne
Erreur de saisie	Inversion lat./lon. ou chiffres incorrects	Saisie manuelle sans vérification automatique	Haute
Dérive GPS	Mauvaise réception satellite, signal instable	Zone forestière, urbaine dense ou conditions météo	Moyenne
Fraude enquêteur	Coordonnées fictives saisies sans déplacement	Pression sur les volumes, absence de supervision	Haute

Il est important de souligner que les **erreurs de projection** constituent un piège méthodologique fréquent et souvent négligé : un analyste non averti pourrait conclure hâtivement qu'un point situé hors du territoire national en EPSG :3857 est nécessairement une erreur GPS, alors qu'il s'agit peut-être simplement d'une confusion de système de coordonnées, facilement corrigible. Ce risque est au cœur du **Piège 1** traité dans ce rapport.

Les **fraudes d'enquêteurs**, bien que rares dans les enquêtes de qualité comme l'EACI, constituent la forme la plus grave d'anomalie GPS car elles sont intentionnelles et potentiellement systématiques. Leur détection via DBSCAN, croisée avec la variable passage, fait l'objet du **Piège 2**.

1.3 Score composite et règles de classification

Le score de qualité global est défini comme la somme de cinq indicateurs binaires complémentaires :

$$\text{Score}_i = \underbrace{\text{hors_mali_reel}_i}_{(\text{Piège 1})} + \text{dans_eau_suspect}_i + \text{zone_humide_twi}_i + \underbrace{\text{doublon}_i}_{(\text{Piège 2})} + \text{suspect_distance}_i$$

$$\text{avec } \text{suspect_distance}_i \in \{0, 1, 2, 3, 4, 5\}$$

TABLE 3. Grille de classification des observations par score composite

Score	Niveau	Signification analytique
0	Bon	Aucun critère violé : observation conservée intégralement dans la base nettoyée.
1 ou 2	À vérifier	Un ou deux critères violés : anomalie mineure ou incertitude — vérification recommandée avant usage.
> 2	Suspect	Trois critères ou plus violés : anomalies multiples convergentes — exclusion ou fusion recommandée.

2 PRÉSENTATION DES DONNÉES ET MÉTHODOLOGIE

2.1 Sources de données mobilisées

L'analyse mobilise trois sources de données complémentaires, toutes issues de la base LSMS-ISA Mali 2017 diffusée par la Banque mondiale.

TABLE 4. Sources de données mobilisées dans l'analyse GPS

Source	Description détaillée	Rôle dans l'analyse
eaci geovariables 2017.csv	Fichier principal : coordonnées GPS de 953 exploitations agricoles + 36 variables géographiques (NDVI, TWI, précipitation, élévation, distance aux routes, densité de population, densité de terres cultivées). Source : MLI 2017 EAC-I v03, Banque mondiale.	Base principale
eaci17 s01p1.csv	Fichier d'identification des ménages enquêtés. Contient les variables grappe, exploitation et passage, permettant de distinguer les doublons légitimes (double visite d'un même ménage) des saisies en double (fraude probable). Piège 2 traité via ce fichier.	Piège 2
rnaturalearth (package R)	Package R fournissant les polygones des frontières administratives du Mali (niveau 1 : régions). Utilisé pour la validation territoriale en EPSG :3857 et UTM Zone 29N. Source : Natural Earth.	Validation géographique

Un point méthodologique important concerne le **jittering** appliqué par la Banque mondiale aux coordonnées GPS. Afin de protéger la confidentialité des ménages enquêtés, chaque coordonnée a été perturbée par l'ajout d'un bruit aléatoire de quelques centaines de mètres. Cette contrainte est inhérente à la politique de diffusion LSMS-ISA. Elle implique que la position exacte de chaque exploitation ne peut pas être déterminée avec précision, et que certains doublons détectés par DBSCAN peuvent être artificiellement créés par ce mécanisme de perturbation — d'où l'importance du Piège 2.

2.2 Packages R utilisés

Package	Fonction principale	Objectif dans l'analyse
<code>sf</code>	Gestion des objets spatiaux	Projections (EPSG :3857, UTM), intersections, buffers
<code>rnaturalearth</code>	Données géographiques	Import des frontières officielles du Mali
<code>osmdata</code>	Données OpenStreetMap	Récupération du réseau hydrographique (zones aquatiques)
<code>units</code>	Gestion des unités	Calcul de surfaces en hectares
<code>dbscan</code>	Clustering spatial	Détection des doublons spatiaux (DBSCAN, eps=500m)
<code>ggplot2</code> <code>geom_sf</code>	+ Visualisation	Cartographie des anomalies GPS

Note technique : L'ensemble des traitements est réalisé sous R. Les packages `sf` et `units` garantissent des calculs géométriques rigoureux (distances en mètres, surfaces en hectares). `osmdata` permet d'intégrer les données hydrographiques pour une détection précise des zones aquatiques (delta intérieur du Niger).

2.3 Architecture du pipeline de validation en six étapes

TABLE 5. *Architecture du pipeline de validation GPS en six étapes séquentielles*

Étape	Critère	Méthode et seuil retenus	Piège
Étape 1	Validation géographique	Intersection géométrique en EPSG :3857 ET UTM Zone 29N + $TWI > Q90 + NDVI < Q5 + popdensity < Q5$	P1
Étape 2	Taxonomie des erreurs	Comparaison des 2 projections + NDVI + distance aux routes	–
Étape 3	Doublons spatiaux	DBSCAN (eps=500m, EPSG :3857) + variable passage et exploitation du fichier s01	P2
Étape 4	Outliers spatiaux	Quantile 95% non-paramétrique des distances au centroïde géographique	–
Étape 5	Score et décisions	Hierarchie de 7 règles de décision documentées et justifiées	P3
Étape 6	Sensibilité	Comparaison Q90%, Q95% et Q97.5% sur les estimations finales	P3

2.4 Justifications des choix méthodologiques clés

Pourquoi deux projections pour la validation territoriale (Piège 1)? La détection des points hors territoire est réalisée successivement en EPSG :3857 (Web Mercator, mètres) et en UTM Zone 29N (projection locale adaptée au Mali). Un point identifié comme hors Mali en EPSG :3857 mais qui rentre dans les frontières en UTM Zone 29N est classé comme erreur de projection, et non comme une vraie anomalie GPS. Cette double vérification évite d'exclure à tort des observations parfaitement valides dont les coordonnées n'ont besoin que d'une simple correction de projection.

Pourquoi DBSCAN et la variable passage (Piège 2)? L'algorithme DBSCAN identifie les points spatialement très proches (dans un rayon de 500 mètres en EPSG :3857) sans supposer de forme particulière pour les clusters. La variable passage permet ensuite de distinguer trois catégories de doublons aux implications analytiques radicalement différentes : le jittering légitime (à fusionner), la double visite d'un même ménage (à conserver), et la fraude probable (à exclure). Une approche naïve traiterait ces trois cas de la même façon, introduisant une perte artificielle d'observations valides.

Pourquoi le quantile 95% plutôt que la règle $\bar{d} + 2\sigma$? Le critère classique $\bar{d} + 2\sigma$ suppose une distribution normale des distances au centroïde. Or, la distribution des exploitations agricoles maliennes présente une asymétrie à droite marquée — l'hypothèse de normalité n'est pas vérifiée. Le quantile 95% est un critère non-paramétrique, robuste à toute forme de distribution, qui garantit que les 5% de points les plus éloignés du centroïde seront systématiquement identifiés.

Choix EPSG :3857 pour toutes les opérations géométriques : les calculs de distances en degrés décimaux (WGS84) sont métriquement incohérents — un degré de longitude ne représente pas la même distance physique selon la latitude. En projetant systématiquement en EPSG :3857 (mètres), toutes les distances sont métriquement rigoureuses. Le rayon DBSCAN de 500 mètres est ainsi physiquement interprétable, contrairement à une valeur en degrés décimaux.

3 RÉSULTATS ET ANALYSE

3.1 Tableau de bord global des anomalies détectées

TABLE 6. *Tableau de bord complet des anomalies GPS — EACI Mali 2017 (N = 953)*

Indicateur	Effectif	Part
Hors Mali réel — vérifié dans 2 projections (Piège 1)	1	0.1%
Erreurs de projection détectées (Piège 1)	0	0%
Zones aquatiques suspects (distance > 50 km frontière)	297	31.2%
Zones humides (TWI > quantile 90)	74	7.8%
Zones non cultivées (NDVI < quantile 5)	47	4.9%
Zones inhabitées (densité population < quantile 5)	41	4.3%
Erreurs de saisie probables (inversion lat./lon.)	1	0.1%
Dérives GPS détectées	5	0.5%
Doublons spatiaux DBSCAN — dont jittering légitime	207 (dont 207)	21.7%
Outliers spatiaux (quantile 95%)	48	5%
Score 0 — Bonne qualité GPS	473	49.6%
Score 1-2 — À vérifier	463	48.6%
Score > 2 — Suspectes	17	1.8%

Lecture globale. Le premier constat est encourageant : avec **49.6%** d’observations sans aucune anomalie détectable, la base EACI 2017 témoigne d’une collecte GPS globalement bien exécutée. Ce taux, remarquablement élevé pour une enquête de terrain en milieu rural africain où les conditions de réception satellite peuvent être dégradées, suggère un bon encadrement des enquêteurs et un dispositif de contrôle qualité adéquat. La **proportion de zones aquatiques suspects** (31.2%) mérite attention : elle reflète en grande partie les exploitations situées dans des zones agricoles éloignées des frontières nationales, comme les plaines irriguées du delta intérieur du Niger, plutôt que de vraies erreurs GPS. Les 207 **doublons détectés** par DBSCAN ne doivent surtout pas être interprétés comme autant d’erreurs avant vérification de leur origine, comme le montre la section suivante.

3.2 Validation géographique et traitement du Piège 1

La première étape du pipeline confronte chaque point GPS au polygone du territoire malien, successivement en EPSG :3857 et en UTM Zone 29N. Cette double vérification est au cœur du **Piège 1**.

Les résultats montrent que **1** point est initialement identifié hors des frontières maliennes en

EPSG :3857. Après vérification en UTM Zone 29N, ce même point reste hors territoire — il s’agit donc d’un **vrai point hors Mali** (1 observation), et non d’une erreur de projection. Aucune erreur de projection n’a été détectée dans cette base : le Piège 1 est traité et documenté, sans impact sur les exclusions. La cause probable de cet unique point aberrant est une inversion de latitude et de longitude lors de la saisie par l’enquêteur, comme le suggère la valeur normale de son NDVI qui indique une zone végétalisée, incompatible avec une localisation hors du territoire malien.

Bilan Piège 1 : la double vérification en deux projections confirme que l’unique point hors territoire est bien une vraie anomalie GPS et non une erreur de projection. Aucune observation valide n’a été exclue par erreur de projection. Le pipeline traite correctement ce piège méthodologique.

3.3 Détection et classification des doublons spatiaux (Piège 2)




FIGURE 1. Répartition des doublons spatiaux par origine — Piège 2 : la quasi-totalité est attribuable au jittering LSMS, non à des erreurs de collecte

L’application de DBSCAN avec un rayon de 500 mètres en EPSG :3857 identifie **207 doublons spatiaux**, soit 21.7% de la base. Ce chiffre pourrait alarmer un analyste non averti. Cependant, la Figure 1 révèle une réalité très différente : **207 doublons sur 207 (100%)** sont attribuables au jittering LSMS légitime. Il s’agit de points appartenant à des grappes différentes dont les coordonnées jitterisées se retrouvent dans un rayon de 500 mètres — une situation entièrement prévisible lorsque la perturbation aléatoire est de l’ordre de quelques centaines de mètres. Ces 207 observations sont des **données parfaitement valides** qu’il convient de fusionner et non d’exclure.

Implication analytique majeure — Piège 2 : si l'on avait appliqué naïvement la règle "tout doublon = erreur = exclusion", on aurait supprimé 207 observations valides, soit 21.7% de la base. Cette perte artificielle aurait réduit la puissance statistique des analyses et potentiellement introduit un biais géographique. La distinction par la variable passage est ici décisive.

3.4 Distribution des distances et détection des outliers spatiaux




FIGURE 2. Distribution des distances au centroïde géographique — asymétrie à droite prononcée justifiant le recours au quantile 95% plutôt qu'à la règle 2-sigma

La Figure 2 illustre la distribution des distances de chaque exploitation au centroïde géographique du nuage de points. Cette distribution présente une **asymétrie à droite prononcée** : la grande majorité des exploitations se concentre dans une zone centrale du territoire malien (entre 100 et 500 km du centroïde), tandis qu'une petite fraction se trouve à des distances considérables. Cette asymétrie valide le choix du quantile 95% comme critère de détection : la règle $\bar{d} + 2\sigma$ supposerait une distribution normale — hypothèse clairement non vérifiée ici. Le seuil retenu est $Q_{0.95} = 650$ km. Les **48 observations** situées au-delà de ce seuil représentent 5% de la base. Ces exploitations sont potentiellement mal localisées, bien que leur situation dans le territoire malien ne permette pas, à elle seule, de conclure à une erreur GPS — d'où le recours au score composite pour la décision finale.

3.5 Répartition par niveau de qualité et décisions de traitement

La Figure 3 synthétise la répartition des 953 exploitations selon le score composite. Les **473 exploitations de bonne qualité (49.6%)** ne présentent aucun des cinq critères d'anomalie :




FIGURE 3. Répartition des exploitations par niveau de qualité GPS — score composite sur cinq critères

elles constituent le cœur de la base nettoyée. Les **463 exploitations à vérifier** (48.6%) ont un score de 1 ou 2, ce qui indique une anomalie mineure liée essentiellement au jittering ou à la proximité d'une zone humide. Enfin, les **17 exploitations suspectes** (1.8%) cumulent au moins trois anomalies et requièrent un traitement prioritaire.


TABLE 7. Décisions de traitement hiérarchisées et leurs justifications

Décision	N	Part	Justification analytique
Exclure hors territoire	1	0.1%	Hors Mali réel dans 2 projections — exclusion certaine
Fusionner jittering	207	21.7%	Doublon légitime LSMS — garder une seule observation
Garder	473	49.6%	Aucune anomalie détectée — conservation intégrale
Imputer coordonnées	10	1%	Outlier isolé à score faible — imputation recommandée
Vérifier manuel	262	27.5%	Zone aquatique ou humide — vérification terrain avant exclusion

La décision “**Garder**” concerne 473 exploitations, soit 49.6% de la base : ces observations sont conservées telles quelles. La décision “**Fusionner jittering**” (207 cas) confirme l’ampleur du phénomène de jittering LSMS — ces observations sont techniquement valides et ne doivent pas être perdues. La décision “**Vérifier manuel**” (262 cas) concerne les exploitations potentiellement en zone humide, pour lesquelles une vérification terrain serait nécessaire avant exclusion définitive. Seul **1 point** est exclu de manière certaine — un résultat frappant qui témoigne de la bonne qualité globale de la collecte EACI 2017.

Localisation géographique des anomalies GPS --- Mali, EACI 2017

Score composite sur 5 critères --- Les points suspects sont rares et dispersés



Source : MLI_2017_EAC-I_v03, Banque mondiale | Traitement : ZONGO, ISEP2 S4

FIGURE 4. Carte géographique des anomalies GPS au Mali — EACI 2017 — Points colorés selon le niveau de qualité du score composite

3.6 Carte de localisation des anomalies GPS

La carte confirme plusieurs observations analytiques importantes. D’abord, les exploitations de **bonne qualité** (points bleus) couvrent l’ensemble du territoire malien de manière cohérente avec la géographie agricole du pays : elles se concentrent dans les zones céréalières du sud, les zones irriguées de l’Office du Niger, et les zones cotonnières de Sikasso. Ensuite, les exploitations **à vérifier** (points orange) présentent une distribution spatiale diffuse, sans concentration particulière dans une région spécifique, ce qui exclut une dérive systématique localisée chez un groupe d’enquêteurs. Enfin, les rares exploitations **suspectes** (points rouges, 17 au total) sont dispersées sur le territoire sans clustering spatial apparent — ce qui suggère des incidents individuels plutôt qu’une fraude organisée ou une dérive systématique de la collecte.

3.7 Estimation des surfaces cultivées (Objectif 4)




FIGURE 5. Distribution des surfaces cultivées estimées — proxy hybrid_V8 appliqué à l’emprise GPS circulaire de rayon 100 m

En l’absence de polygones GPS de parcelles — les coordonnées EACI étant des points jitterisés et non des contours d’exploitations — la superficie cultivée est estimée par la formule :

$$\widehat{\text{Superficie}}_i = \pi \times (100)^2 \times \frac{\text{hybrid_V8}_i}{100} \quad \text{en ha}$$

où hybrid_V8 est la densité de terres cultivées dans un voisinage de l’exploitation, exprimée en pourcentage, et 100 mètres est le rayon du buffer GPS.

La surface cultivée moyenne estimée de **0.56 ha** est cohérente avec les données disponibles sur les exploitations agricoles maliennes, où les superficies moyennes varient généralement entre 0,3 et 2 ha selon le système de production (cultures pluviales, irriguées, maraîchage). La

distribution est asymétrique à droite, avec une forte concentration d'exploitations autour de 0,3-0,8 ha et une queue droite correspondant aux grandes exploitations irriguées.

Limite importante à documenter : la variable `s7cq07` (superficie déclarée en ha) est indisponible dans le fichier `eaci_geovariables_2017.csv`, toutes les valeurs étant manquantes. L'estimation via `hybrid_v8` constitue le meilleur proxy disponible mais ne saurait remplacer la superficie réellement déclarée par l'agriculteur. Cette limite devra être mentionnée dans tout usage analytique de ces estimations.

3.8 Impact des corrections et analyse de sensibilité (Objectif 5 — Piège 3)

TABLE 8. Comparaison des estimations avant et après corrections GPS

Étape	N	Surf. moy. (ha)	NDVI moyen	hybrid V8 (%)	Dist. moy. (km)
Avant correction	953	0.561	0.26	17.85	307.99
Après correction	952	0.561	0.26	17.86	307.81

Le tableau ci-dessus compare les estimations des principaux indicateurs avant et après application des corrections GPS. Le constat est frappant : les corrections n'apportent quasiment **aucune variation mesurable sur les estimations**, la surface cultivée moyenne et le NDVI restant strictement identiques. Cette stabilité, surprenante à première vue, s'explique mathématiquement par le faible nombre d'observations exclues (1 point sur 953, soit 0.1%) : avec un seul point exclu, l'impact sur les moyennes est négligeable.

Ce résultat doit être interprété positivement et non comme un échec du pipeline : il confirme que la base EACI 2017 est **de bonne qualité initiale** et que les anomalies détectées sont rares et isolées. Il ne signifie pas que le pipeline est inutile — au contraire, il documente rigoureusement l'état de la base, fournit une base méthodologique solide pour les analyses subséquentes, et prévient toute critique ultérieure sur la qualité des données utilisées.

TABLE 9. Analyse de sensibilité des estimations au seuil d'exclusion des outliers

Quantile	N conservés	N exclus	Pct exclus	Surf. moy. (ha)	NDVI moyen
Q90%	856	97	10.2	0.612	0.2688
Q95%	904	49	5.1	0.590	0.2659
Q97.5%	928	25	2.6	0.575	0.2627

L'analyse de sensibilité teste la robustesse des estimations à trois seuils alternatifs. La surface cultivée moyenne varie de 0.612 ha (Q90%) à 0.575 ha (Q97.5%), soit un écart de 0.037 ha




FIGURE 6. Robustesse des estimations au choix du seuil d'exclusion — faible variation de la surface moy. entre Q90 et Q97.5

— moins de 6% de variation relative. Cette faible variation confirme que le choix du seuil Q95% n'est pas déterminant pour les conclusions analytiques. Le **Piège 3** est ici traité : les estimations sont stables et robustes à la spécification du seuil d'exclusion.

3.9 Vérification du biais de sélection (Piège 3)

\begin{table}[H] \caption{Biais de sélection — différence NDVI exclus vs conservés = 3% (seuil critique : 10\%)}\end{table}

Statut	N	NDVI	TWI	Pluie (mm)	Route (km)	Alt. (m)
Conservés	952	0.2600	14.493	629	11.9	304
Exclus	1	0.2522	13.000	445	3.0	214

\end{table}




FIGURE 7. Comparaison exclus vs conservés sur quatre indicateurs géographiques — vérification de l'absence de biais de sélection systématique (Piège 3)

La vérification du biais de sélection constitue l'élément central du **Piège 3**. Le tableau et la Figure 7 comparent les caractéristiques géographiques moyennes des observations exclues et des observations conservées sur cinq indicateurs clés.

La différence de NDVI entre les deux groupes est de **3%**, bien en dessous du seuil critique de 10%, ce qui ne permet pas de conclure à un biais de sélection comme analytiquement significatif.

On observe des différences sur certains indicateurs (précipitation, élévation), mais celles-ci doivent être interprétées avec prudence : l'observation exclue est **unique** (1 point), ce qui rend toute comparaison statistiquement fragile.

L'essentiel est que les exclusions réalisées ne créent pas de biais géographique systématique détectable sur les indicateurs de végétation, d'humidité et de proximité aux infrastructures.

Conclusion Piège 3 : avec 3% de différence NDVI (inférieur au seuil de 10%), les exclusions réalisées dans ce pipeline ne créent pas de biais de sélection géographique systématique. La base nettoyée est représentative de l'ensemble du territoire enquêté. Le Piège 3 est traité et documenté.

4 DISCUSSION, FORCES ET LIMITES

4.1 Forces méthodologiques de l'approche

L'approche déployée dans ce rapport présente plusieurs forces qui la distinguent des diagnostics GPS usuels pratiqués dans les enquêtes agricoles africaines.

Reproductibilité totale. L'ensemble du pipeline est codé sous R, documenté et portable. Tout analyste disposant des mêmes données d'entrée peut reproduire exactement les mêmes résultats en exécutant le script. Cette propriété de reproductibilité est le fondement de la rigueur data-scientifique et constitue un préalable indispensable dans un contexte de production statistique publique.

Double vérification des projections (Piège 1). En testant chaque point dans deux systèmes de coordonnées différents, le pipeline élimine le risque de faux positifs liés à une confusion de projection. Cette étape, souvent négligée dans les analyses GPS standard, est pourtant cruciale : une erreur de projection est corrigible, une vraie anomalie GPS ne l'est pas.

Distinction fine des origines de doublons (Piège 2). L'utilisation conjointe de DBSCAN et de la variable passage permet de distinguer trois catégories de doublons aux implications analytiques radicalement différentes : le jittering légitime (à fusionner), la double visite (à conserver), et la fraude probable (à exclure). Cette distinction, absente des analyses GPS naïves, évite une perte artificielle et non documentée d'observations valides.

Documentation du biais de sélection (Piège 3). La comparaison systématique des caractéristiques des observations exclues et conservées transforme une décision d'exclusion en une décision documentée, défendable devant un auditeur externe. Cette démarche est indispensable dans tout rapport statistique destiné à informer des décisions de politique publique.

Robustesse technique : utilisation systématique d'EPSG :3857 pour tous les calculs géométriques (distances métriquement cohérentes), DBSCAN avec rayon physiquement interprétable en mètres, et quantile 95% non-paramétrique robuste à l'asymétrie de la distribution. Ces choix sont justifiés et reproductibles.

4.2 Limites méthodologiques

Limite 1 — Le jittering comme source de faux positifs DBSCAN. La perturbation aléatoire appliquée par la Banque mondiale peut rapprocher artificiellement des exploitations distinctes jusqu'à les faire apparaître comme des doublons. Avec un rayon DBSCAN de 500 mètres, toute paire d'exploitations dont les vraies coordonnées sont distantes de moins de 500 mètres diminuées de l'amplitude du jitter sera détectée comme doublon. Cette limite est inhérente au protocole de diffusion LSMS-ISA et ne peut être surmontée qu'avec accès aux coordonnées non jitterisées, disponibles uniquement auprès de la Banque mondiale sous accord de confidentialité.

Limite 2 — L'approximation des zones aquatiques. Le critère de distance à la frontière supérieure à 50 km est une approximation grossière. Il ne capture pas le delta intérieur du Niger — l'une des plus grandes plaines d'inondation d'Afrique de l'Ouest — qui se situe au cœur du territoire malien, loin des frontières. L'intégration d'une couche hydrographique issue d'OpenStreetMap ou du réseau HDX permettrait une détection plus précise et plus rigoureuse des zones potentiellement aquatiques.

Limite 3 — La surface cultivée comme proxy. L'estimation de la superficie via `hybrid_V8` constitue une approximation méthodologique reconnue, mais présente deux biais potentiels. D'abord, elle suppose que la densité de terres cultivées dans le voisinage du point GPS est représentative de l'exploitation enquêtée, ce qui peut ne pas être le cas dans les zones de fragmentation agricole élevée. Ensuite, le rayon de 100 mètres choisi pour le buffer GPS est arbitraire et ne reflète pas nécessairement la taille réelle des parcelles maliennes, qui varient considérablement selon les régions et les systèmes de production.

Limite 4 — Le biais inhérent au quantile 95%. Ce seuil marque mécaniquement 5% des observations comme suspectes, indépendamment de leur nature réelle. L'analyse de sensibilité montre toutefois que ce choix n'affecte pas significativement les estimations finales, ce qui atténue considérablement cette limite.

CONCLUSION ET RECOMMANDATIONS

Une mission remplie

Ce rapport avait pour ambition d'établir un diagnostic complet, rigoureux et reproductible de la qualité des coordonnées GPS de la base EACI 2017 au Mali, en anticipant et en traitant explicitement les pièges méthodologiques que le praticien non averti commettrait facilement.

Au terme de ce travail, le bilan est clair et positif : les **cinq objectifs pédagogiques** assignés ont été pleinement atteints, les **six étapes** du traitement statistique ont été documentées et justifiées, et les **trois pièges méthodologiques** ont été explicitement identifiés, traités et documentés avec preuves empiriques à l'appui. La base EACI 2017 présente une **qualité GPS globalement satisfaisante** : 49.6% d'observations sans anomalie détectable, seul 1 point exclu définitivement sur 953, et des corrections sans impact mesurable sur les estimations finales.

La principale anomalie structurelle détectée n'est pas une erreur de collecte mais une contrainte de diffusion : le **jittering LSMS**, appliqué pour protéger la confidentialité des ménages, génère des doublons apparents (207 cas) qui doivent être identifiés et traités comme tels. Cette distinction entre anomalie réelle et artefact méthodologique est au cœur de la contribution analytique de ce rapport.

Des avancées méthodologiques

Sur le plan technique, ce projet illustre la mise en œuvre de plusieurs compétences avancées du statisticien en exercice :

1. **Rigueur géométrique** : Reprojection systématique en EPSG :3857 pour des calculs métriques exacts, et double vérification en UTM Zone 29N pour le traitement du Piège 1.
2. **Clustering spatial argumenté** : Application de DBSCAN avec un rayon physiquement interprétable (500 m) et enrichissement par la variable passage pour la distinction des origines de doublons (Piège 2).
3. **Statistiques non-paramétriques** : Utilisation du quantile 95% comme seuil robuste, plus adapté à la distribution asymétrique des distances que le critère $\bar{d} + 2\sigma$.
4. **Documentation du biais de sélection** : Comparaison systématique exclus vs conservés sur cinq indicateurs géographiques pour la validation du Piège 3.

Recommandations opérationnelles

1. **Former les enquêteurs à la collecte GPS de qualité** : attendre la stabilisation du signal (minimum 5 satellites), vérifier la cohérence géographique immédiate du point enregistré, et utiliser systématiquement les fonctionnalités de contrôle de qualité des appareils GPS.
2. **Déployer un contrôle GPS en temps réel (CAPI)** : intégrer dans l'application mobile de collecte une alerte automatique si le point enregistré se situe hors de la zone géographique assignée à l'enquêteur ou dans une zone identifiée comme inhabitable.
3. **Implémenter la double mesure GPS** : enregistrer deux prises de coordonnées indépendantes — au début et à la fin de l'entretien — pour détecter les dérives instrumentales et identifier les fraudes par incohérence temporelle.
4. **Automatiser le pipeline de validation** : intégrer ce script R comme étape systématique post-collecte, avant toute diffusion des données ou lancement d'analyses statistiques sur les données EACI.
5. **Auditer les performances GPS par enquêteur** : produire des indicateurs individuels de qualité GPS et les utiliser comme critère d'évaluation des enquêteurs, afin de déceler les dérives précoces.
6. **Enrichir la détection des zones aquatiques** : intégrer les couches hydrographiques d'OpenStreetMap ou du réseau HDX Mali pour une détection précise des zones en eau, indépendante de la distance aux frontières nationales.

Perspectives

Ce pipeline ouvre de vastes perspectives d'approfondissement. La base nettoyée pourrait servir de fondation à des analyses spatiales avancées : estimation des superficies cultivées par télémétrie via des données Sentinel-2, croisement avec des données d'imagerie satellitaire NDVI pour la validation des rendements déclarés, ou modélisation de la distribution géographique des systèmes de production. L'extension du pipeline aux autres vagues de l'EACI (2014, 2018) permettrait également une analyse longitudinale de l'évolution de la qualité GPS, et contribuerait à identifier les régions ou les périodes où la collecte est systématiquement plus difficile.

En définitive, ce projet démontre qu'il est possible, avec rigueur et méthode, de transformer des

données GPS brutes en une information géographique fiable et exploitable. Dans un contexte où les politiques agricoles maliennes s'appuient de plus en plus sur des analyses spatiales pour cibler les interventions, garantir la qualité des coordonnées GPS n'est plus un luxe technique : **c'est un préalable indispensable à toute analyse agricole de qualité.**

*Garantir la qualité des coordonnées
GPS n'est plus un luxe technique :*
**c'est un préalable indispensable à
toute analyse agricole de qualité.**

Fin du rapport

Rapport produit avec R Markdown (xelatex) — ENSAE Pierre Ndiaye, Dakar

20 mai 2026
